Taller AHA

Ejercicio Reflexivo:

Cómo impacta en el rendimiento del modelo de IA

1. **Exploración (Búsqueda Global)**
    - Permite que el algoritmo **no se quede atrapado en mínimos locales** explorando diferentes regiones del espacio de soluciones.
    - En la optimización de **hiper parámetros de una red neuronal**, una exploración adecuada evita sesgos en configuraciones subóptimas.
2. **Explotación (Búsqueda Local)**
    - Ayuda a refinar soluciones cercanas a las mejores ya encontradas.
    - En **selección de características**, permite elegir combinaciones más precisas que optimicen el rendimiento del modelo de IA.

Ejercicio Práctico:

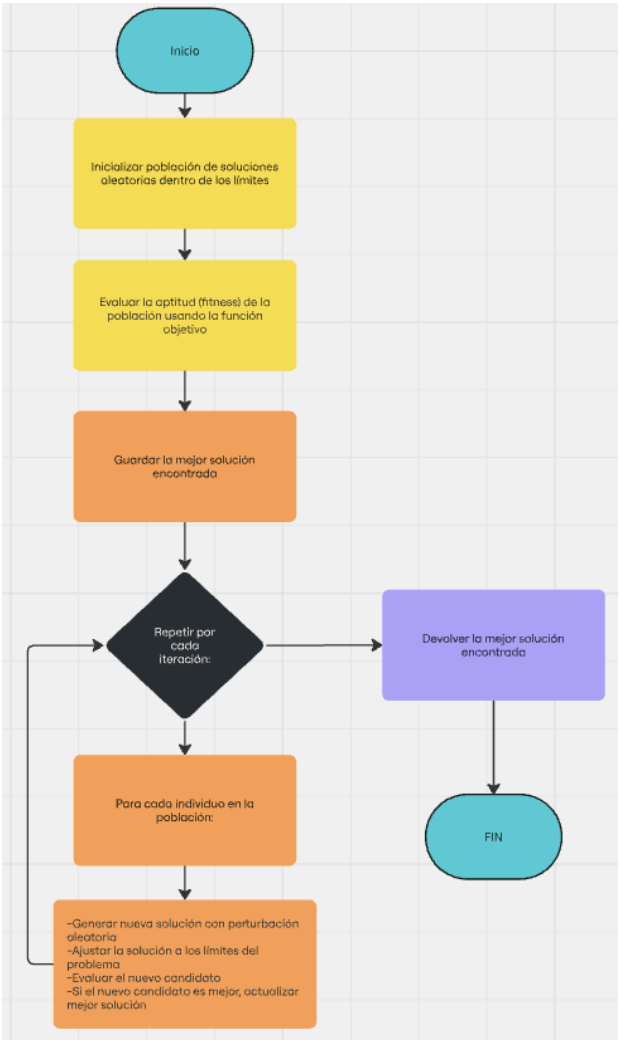

PSEUDOCÓDIGO:

```
Función AHA_Optimización(f, límites, tamaño_población, iteraciones):
    Dim ← longitud(límites)  # Número de dimensiones del problema
    Población ← Generar valores aleatorios dentro de los límites
    Mejor_Solución ← Población[0]
    Mejor_Fitness ← f(Mejor_Solución)
    Para t en 1 hasta iteraciones hacer:
        Para cada individuo en Población hacer:
            # Crear una nueva solución con una perturbación aleatoria
            Candidato ← Individuo + Normal(0, 0.1, Dim)
            Candidato ← Limitar dentro de los límites
            # Evaluar el candidato
            Fitness_Candidato ← f(Candidato)
            # Si es mejor, actualizar
            Si Fitness_Candidato < Mejor_Fitness entonces:
                Mejor_Solución ← Candidato
                Mejor_Fitness ← Fitness_Candidato
            Individuo ← Candidato  # Actualizar la población
    Retornar Mejor_Solución, Mejor_Fitness
```

¿Cómo podrías modificar el AHA para que sea más eficiente en problemas de alta dimensionalidad?

1. **Reducir la cantidad de actualizaciones innecesarias:**
    - Introducir una métrica de convergencia para evitar cálculos redundantes.
2. **Adaptar el tamaño de la perturbación:**
    - Usar un parámetro de exploración que se reduzca con el tiempo para evitar cambios grandes en etapas finales.
3. **Incorporar mecanismos de selección elitista:**
    - Guardar un subconjunto de las mejores soluciones para mantener la diversidad sin perder soluciones óptimas.
4. **Paralelización:**
    - Evaluar múltiples soluciones simultáneamente usando procesamiento en paralelo.

Ejercicio Reflexivo:

Importancia de la capacidad de memoria del AHA en la optimización de hiper parámetros

El **Algoritmo del Colibrí Artificial (AHA)** incorpora un mecanismo de memoria que le permite **recordar y utilizar soluciones previas**. Esto es clave en la **optimización de hiper parámetros** porque evita explorar configuraciones ineficientes repetidamente y ayuda a acelerar la convergencia hacia una mejor solución.

Ejercicio Práctico:

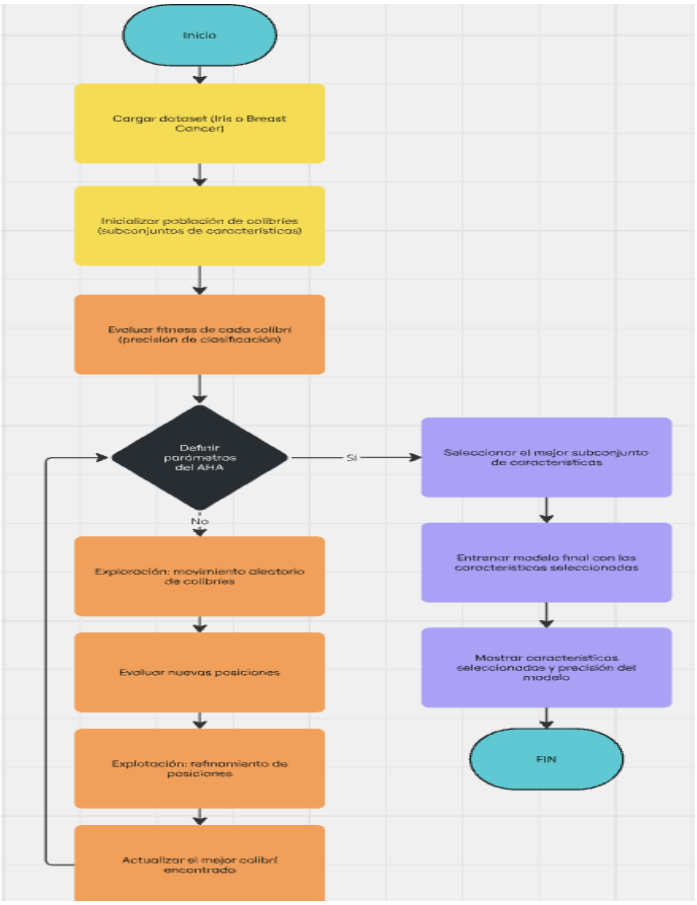

PSEUDOCÓDIGO:

Inicio

1. Cargar dataset (Iris o Breast Cancer)

2. Inicializar población de colibríes (cada uno representa un subconjunto de características)

3. Evaluar la aptitud de cada colibrí usando la precisión de clasificación

4. Definir los parámetros del algoritmo (máx. iteraciones, tamaño de población, etc.)

5. Mientras no se cumpla el criterio de parada:

    6. Fase de exploración:

        - Ajustar posiciones de los colibríes (movimiento aleatorio en el espacio de características)

        - Evaluar la nueva posición

7. Fase de explotación:

   - Refinar posiciones basadas en las mejores soluciones encontradas

   - Actualizar el mejor colibrí encontrado

8. Aplicar reglas de actualización y reemplazo

9. Seleccionar el mejor subconjunto de características

10. Entrenar modelo final con las características seleccionadas

11. Mostrar resultados (características seleccionadas y precisión)

Fin

Ventajas del Algoritmo del Colibrí Artificial (AHA) sobre un enfoque aleatorio en la selección de características

La **selección de características** es crucial en **aprendizaje automático**, ya que elegir las variables correctas mejora el rendimiento del modelo.

Un enfoque **aleatorio** simplemente selecciona subconjuntos de características sin evaluar tendencias previas, mientras que el **AHA** optimiza la selección basándose en la exploración y explotación del espacio de soluciones.

Ejercicio Final:

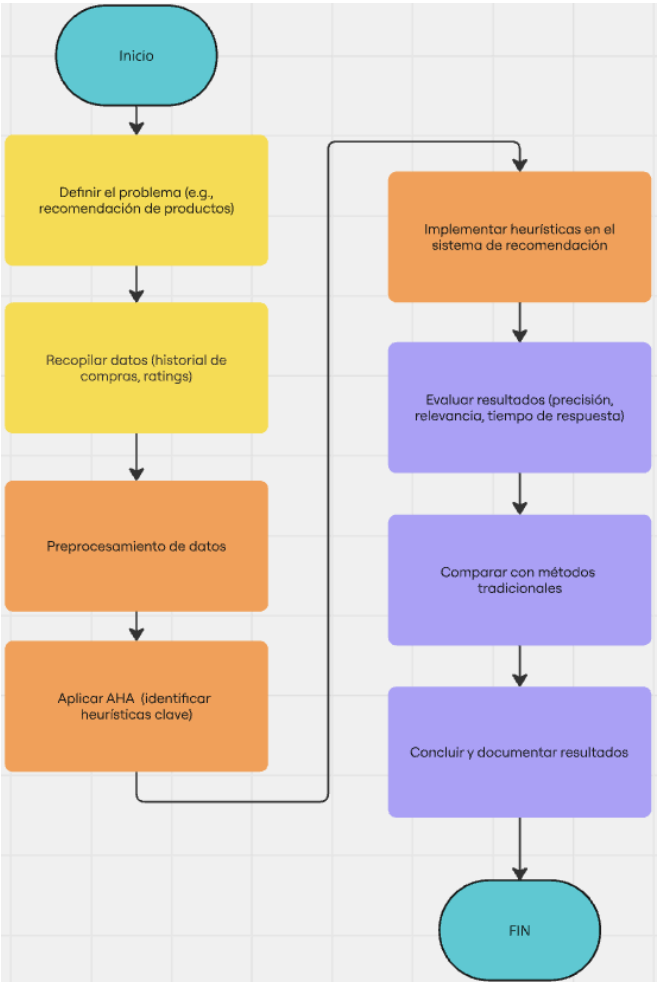

PSEUDOCÓDIGO:

1. Inicio

2. Definir el problema:

   - Objetivo: Mejorar la recomendación personalizada.

   - Contexto: Sistema de e-commerce.

3. Recopilar datos:

   - Cargar dataset de historial de compras y ratings.

4. Preprocesamiento de datos:

   - Limpiar datos (eliminar valores nulos, normalizar).

   - Dividir en conjunto de entrenamiento y prueba.

5. Aplicar AHA:

- Identificar heurísticas clave (e.g., "Los usuarios tienden a comprar productos similares a los que ya han comprado").

- Simplificar reglas de decisión basadas en heurísticas.

6. Implementar heurísticas en el sistema:

- Crear un modelo basado en reglas heurísticas.

- Integrar el modelo en el sistema de recomendación.

7. Evaluar resultados:

- Medir precisión (accuracy) y relevancia (F1-score).

- Medir tiempo de respuesta del sistema.

8. Comparar con métodos tradicionales:

- Comparar resultados con un sistema basado en machine learning (e.g., filtrado colaborativo).

9. Concluir y documentar:

- Analizar si el AHA mejora la eficiencia sin comprometer la calidad.

- Documentar hallazgos y limitaciones.

10. Fin

Adaptación del Algoritmo del Colibrí Artificial (AHA) en Visión por Computadora y NLP

El **AHA** es un algoritmo bioinspirado que se puede adaptar para optimizar modelos en **Visión por Computadora** y **Procesamiento de Lenguaje Natural (NLP)**. Su capacidad para **explorar y explotar soluciones de manera eficiente** lo hace útil en tareas de ajuste de hiper parámetros, selección de características y optimización de arquitecturas de redes neuronales.

Adaptación del AHA en Visión por Computadora

En tareas como **clasificación de imágenes, detección de objetos y segmentación**, el AHA puede ayudar a optimizar:

Hiper Parámetros de CNs (Redes Neuronales Convolucionales)

- Ajustar **tamaño de filtros**, **número de capas**, **learning rate**, etc.
- AHA explora configuraciones eficientes y explota las mejores encontradas.

Selección de características en imágenes

- AHA puede encontrar **las características más relevantes** en la extracción de bordes, texturas o colores para mejorar la clasificación.
- Se evita la redundancia en datos, reduciendo el costo computacional.

Optimización de arquitecturas en Transfer Learning

- Encontrar la mejor combinación de capas congeladas y entrenables en modelos pre entrenados como **ResNet, VGG o Efficient Net**.